

Міністерство освіти і науки України
Львівський національний університет імені Івана Франка
Факультет прикладної математики та інформатики
Кафедра прикладної математики

Курсова робота

**Методи наближення розв'язків інтегральних рівнянь
за допомогою нейронних мереж**

Студентка групи ПМПм-12:
Горбачук Богдана Андріївна
спеціальність 113 Прикладна математика

Науковий керівник:
кандидат фізико-математичних наук
Переймибіда Андрій Андрійович

Львів – 2026

Зміст

Вступ	4
1 Постановка задачі та її коректність. Параметризація	6
1.1. Постановка крайової задачі та аналіз її коректності	6
1.2. Параметризація та виділення особливості ядра	9
1.3. Повна дискретизація методом квадратур	10
2 Математична модель нейромережевої апроксимації та програмна реалізація	13
2.1. Архітектура багат шарового перцептрона як універсального апроксиматора	14
2.2. Фізично-інформована функція втрат та оптимізація параметрів	15
2.3. Програмний комплекс та математичний зв'язок з інтерфейсом	17
2.4. Моніторинг навчального процесу та інтерпретація результатів	19
3 Результати чисельних експериментів	23
3.1. Конфігурація обчислювального середовища	23
3.2. Приклад 1. Зміщене коло	24
3.3. Приклад 2. Гантелеподібна область	26
3.4. Приклад 3. Еліптична область	27

	3
Висновки	29
Прикінцеві положення	31
Список використаних джерел	35

Вступ

Актуальність теми. Крайові задачі для диференціальних рівнянь у частинних похідних (зокрема, рівняння Лапласа) становлять математичну основу багатьох процесів у фізиці, інженерії та моделюванні екосистем. Одним із найефективніших підходів до їх розв’язування є метод граничних інтегральних рівнянь, який дозволяє зменшити розмірність задачі на одиницю шляхом перенесення обчислень на межу області.

Проте класичні чисельні підходи, такі як метод Нистрьома або метод скінченних елементів, зіштовхуються із суттєвими обчислювальними труднощами, коли геометрія області ускладнюється (наприклад, має увігнутості чи значне витягнення), а ядра інтегральних операторів містять логарифмічні сингулярності. У таких випадках формування та прямуруке обернення щільних матриць систем лінійних алгебраїчних рівнянь (СЛАР) вимагає значних ресурсів пам’яті (обчислювальна складність $O(N^3)$), а самі матриці часто стають погано зумовленими, що призводить до катастрофічного зростання похибки округлення.

Сучасний розвиток наукового машинного навчання (Scientific Machine Learning, SciML) відкрив принципово новий напрямок — фізично-інформовані нейронні мережі (Physics-Informed Neural Networks, PINN). Застосування цього безсіткового підходу дозволяє замінити ресурсомісткий етап обернення гігантських матриць на ітераційний процес нелінійної оптимізації параметрів нейромережі. Великою перевагою є те, що замість дискретного набору точок на виході ми отримуємо неперервну, аналітично задану функцію розв’язку. Дослідження ефективності інтеграції класичних тригонометричних квадратур для обробки сингулярностей безпосередньо у функцію втрат нейромережових моделей є надзвичайно актуальною науково-практичною задачею на стику прикладної математики та Data Science.

Об’єкт дослідження — процеси наближеного розв’язування крайових задач математичної фізики за допомогою методу граничних інтегральних

рівнянь.

Предмет дослідження — математичні моделі, тригонометричні квадратурні методи та архітектури багат шарових перцептронів для безсіткової апроксимації розв’язків граничних інтегральних рівнянь першого роду з логарифмічними сингулярностями ядра.

Мета дослідження — розробка, програмна реалізація та чисельне дослідження ефективності гібридного чисельно-нейромережевого методу (PINN) для знаходження неперервної апроксимації густини потенціалу в задачах Діріхле для рівняння Лапласа у двовимірних областях зі складною геометрією межі.

Для досягнення поставленої мети необхідно виконати такі **завдання**:

1. Дослідити математичну постановку крайової задачі Діріхле для рівняння Лапласа та формалізувати процес її зведення до граничного інтегрального рівняння першого роду.
2. Опрацювати математичний апарат спеціальних тригонометричних квадратур для аналітичного виділення та коректної обробки логарифмічної сингулярності ядра інтегрального оператора.
3. Розробити та обґрунтувати архітектуру нейромережевої моделі на основі багат шарового перцептрона та інтегрувати квадратурні коефіцієнти безпосередньо у цільову функцію втрат (Loss function).
4. Реалізувати розроблений алгоритм у вигляді інтерактивного програмного комплексу мовою Python з використанням фреймворків PyTorch та Streamlit.
5. Провести серію чисельних експериментів для областей різної конфігурації (зміщене коло, «гантеля», еліпс), виконати порівняльний аналіз точності відносно класичного методу розв’язання СЛАР та дослідити вплив гіперпараметрів мережі (кількості епох, нейронів, швидкості навчання) на процес збіжності алгоритму.

Розділ 1

Постановка задачі та її коректність.

Параметризація

У цьому розділі наведено математичне формулювання задачі Діріхле для рівняння Лапласа в частково необмеженій області, а також обґрунтовано коректність задачі, зокрема єдиність та існування її розв'язку. Окрім цього, розглянуто параметризацію межі області та повну дискретизацію еквівалентного інтегрального рівняння за допомогою методу квадратур.

1.1. Постановка крайової задачі та аналіз її коректності

Нехай D_1 — верхня півплощина в R^2 з межею Γ_1 , $D_2 \subset D_1$ — обмежена область з межею Γ_2 і $D = D_1 \setminus \overline{D_2}$. Ми припускаємо, що $\Gamma_2 \in C^2$. Необхідно знайти обмежену функцію u , яка задовольняє рівняння Лапласа

$$\Delta u = 0 \quad \text{в} \quad D \quad (1.1)$$

та крайові умови Діріхле

$$u = f_i \quad \text{на} \quad \Gamma_i, \quad i = 1, 2. \quad (1.2)$$

За наявності (обмежених) достатньо гладких неперервних функцій f_i , заданих на межах Γ_i , $i = 1, 2$, розглянемо задачу для знаходження деякої функції $u \in C^2(D) \cup C(\overline{D})$, яка задовольняє рівняння Лапласа (1.1) з крайовими умовами Діріхле (1.2).

Для доведення єдиності класичного розв'язку задачі Діріхле для рівняння Лапласа розглянемо наступні означення та теорему.

Означення 1.1.1. *Двічі неперервно-диференційовна дійснозначна функція u , визначена в області $D \subset R^2$, називається гармонічною, якщо вона задовольняє рівняння Лапласа (1.1).*

Теорема 1.1.2. *Задача Діріхле для рівняння Лапласа має щонайбільше один розв'язок.*

Доведення. Нехай u_1 та u_2 — два розв'язки задачі Діріхле. Тоді їх різниця $u = u_1 - u_2$ також задовольняє рівняння Лапласа (1.1) та однорідну граничну умову:

$$u = 0 \quad \text{на} \quad \Gamma, \quad \Gamma = \Gamma_1 \cup \Gamma_2$$

Оскільки u — гармонічна функція, неперервна до межі області, то згідно з принципом максимуму та мінімуму для гармонічних функцій, вона набуває свого максимуму та мінімуму лише на межі області. З умови $u = 0$ на Γ маємо $u = 0$ в D . Таким чином, $u_1 = u_2$, що доводить єдиність розв'язку задачі Діріхле. $\square$

Отже, можна стверджувати, що задача Діріхле для рівняння Лапласа в частково необмеженій області має не більше одного розв'язку за умови достатньої гладкості межі Γ_i та неперервності функцій f_i .

Означення 1.1.3. *Для заданої функції $\varphi \in C(\Gamma_2)$, функція*

$$u(x) = \int_{\Gamma_2} \varphi(y) \Phi(x, y) ds(y), \quad x \in D \quad (1.3)$$

називається потенціалом простого шару. Тут

$$\Phi(x, y) = \frac{1}{2\pi} \ln \frac{1}{|x - y|}, \quad x, y \in R^2, \quad x \neq y \quad (1.4)$$

— фундаментальний розв’язок рівняння Лапласа, $|x - y|$ — відстань між точками x та y .

Задачу (1.1)–(1.2) будемо розв’язувати зведенням до інтегрального рівняння першого роду, застосовуючи метод функції Гріна [1, 2, 4].

Означення 1.1.4. Функція Гріна $G(x, y)$ визначається так, що для $x \neq y$ вона задовольняє рівняння Лапласа в області D_1 :

$$\Delta_x G(x, y) = 0, \quad x \in D_1, \quad x \neq y,$$

де Δ_x — оператор Лапласа по змінній x . У точці $x = y$ функція $G(x, y)$ має сингулярність, і вона повинна задовольняти умову:

$$\Delta_x G(x, y) = -\delta(x - y),$$

де $\delta(x - y)$ — дельта-функція Дірака, яка моделює точкове джерело в точці y , $G(x, y) = 0$, $x \in \partial D_1$.

У R^2 для рівняння Лапласа функція Гріна має вигляд:

$$G(x, y) = \Phi(x, y), \quad x \neq y.$$

Для області $D_1 \subset R^2$ функція Гріна задається як

$$G(x, y) = \Phi(x, y) + v(x, y),$$

де $v(x, y)$ — гармонічна функція, така, що $G(x, y) = 0$, $x \in \Gamma_1$. Для верхньої півплощини маємо:

$$G(x, y) = \Phi(x, y) - \Phi(x, y^*), \quad y^* = (y_1, -y_2).$$

Тоді відоме подання розв’язку, що задовольняє рівняння Лапласа u :

$$u(x) = \int_{\Gamma_2} \varphi(y) G(x, y) ds(y) - \int_{\Gamma_1} f_1(y) \frac{\partial G(x, y)}{\partial \nu(y)} ds(y), \quad x \in D. \quad (1.5)$$

Отже, отримано інтегральне рівняння першого роду, що містить слабо-сингулярні ядра (ядро потенціалу простого шару та нормальної похідної), зокрема і з логарифмічною особливістю. Можна показати, що при $x \rightarrow \Gamma_2$ отримаємо:

$$\int_{\Gamma_2} \varphi(y) G(x, y) ds(y) = f_2(x) + \int_{\Gamma_1} f_1(y) \frac{\partial G(x, y)}{\partial \nu(y)} ds(y), \quad x \in \Gamma_2. \quad (1.6)$$

Теорема 1.1.5. Для всіх $f_1 \in L^2(\Gamma_1)$, $f_2 \in C^{1,\alpha}(\Gamma_2)$ існує єдиний розв'язок інтегрального рівняння (1.6) $\varphi \in C^{0,\alpha}(\Gamma_2)$.

Тут $C^{0,\alpha}(\Gamma_2)$, $C^{1,\alpha}(\Gamma_2)$, $0 < \alpha < 1$ — простори Гьольдера. Тепер для вихідної крайової задачі (1.1)–(1.2) можна на основі теорем 1.2 та 1.3 довести її коректність.

Теорема 1.1.6. Для всіх $f_1 \in L^2(\Gamma_1)$, $f_2 \in C^{1,\alpha}(\Gamma_2)$ існує єдиний розв'язок $u \in C^2(D) \cap C(\overline{D})$ крайової задачі (1.1)–(1.2).

1.2. Параметризація та виділення особливості ядра

Для подальшого чисельного інтегрування виконаємо параметризацію межей області:

$$\begin{aligned}\Gamma_1 &= \{x_1(t) = (t, 0) \mid t \in (-\infty, +\infty)\}, \\ \Gamma_2 &= \{x_2(t) = (x_{21}(t), x_{22}(t)) \mid t \in [0, 2\pi]\}.\end{aligned}$$

Врахуємо, що $|x_2'(t)| > 0$. З інтегрального рівняння (1.6) отримаємо:

$$\frac{1}{2\pi} \int_0^{2\pi} \mu(\tau) H(t, \tau) d\tau = f^*(t), \quad t \in [0, 2\pi], \quad (1.7)$$

де

$$f^*(t) = \tilde{f}_2(t) + \int_{-\infty}^{+\infty} \tilde{f}_1(\tau) L(t, \tau) d\tau, \quad (1.8)$$

$$\begin{aligned}\mu(t) &= \varphi(x_2(t)) |x_2'(t)|, \\ \tilde{f}_1(t) &= f_1(x_1(t)), \quad \tilde{f}_2(t) = f_2(x_2(t)), \\ H(t, \tau) &= G(x_2(t), x_2(\tau)), \\ L(t, \tau) &= -\frac{\partial G}{\partial y_2}(x, y) \Big|_{x=x_2(t), y=x_1(\tau)}.\end{aligned}$$

У даній задачі наявне сингулярне ядро, яке виникає при використанні функції Гріна для рівняння Лапласа, коли точка інтеграції наближається до точки спостереження. Оскільки задача має крайові умови, то це важливо

для того, щоб правильно відобразити вплив меж на розв'язок. Саме тому зробимо такі еквівалентні перетворення для виділення особливості:

$$H(t, \tau) = H_1(t, \tau) \ln \left(\frac{4}{e} \sin^2 \frac{t - \tau}{2} \right) + H_2(t, \tau),$$

$$H_1(t, \tau) = -\frac{1}{2},$$

$$H_2(t, \tau) = \begin{cases} H(t, \tau) - H_1(t, \tau) \ln \left(\frac{4}{e} \sin^2 \frac{t - \tau}{2} \right), & t \neq \tau \\ \frac{1}{2} \ln \frac{1}{e|x'_2(t)|^2}, & t = \tau \end{cases}$$

Отже, маємо еквівалентне представлення:

$$\frac{1}{2\pi} \int_0^{2\pi} \mu(\tau) \left\{ H_1(t, \tau) \ln \left(\frac{4}{e} \sin^2 \frac{t - \tau}{2} \right) + H_2(t, \tau) \right\} d\tau = f^*(t), \quad t \in [0, 2\pi]. \quad (1.9)$$

1.3. Повна дискретизація методом квадратур

Процес повної дискретизації задачі включає заміну неперервних виразів дискретними аналогами для подальшого чисельного розв'язання. Зокрема, розглядаються методи апроксимації інтегралів за допомогою квадратурних формул, таких як сімс-квадратури. Особлива увага приділяється заміні функцій і їхніх похідних у вузлах дискретизації, що дозволяє звести задачу до системи лінійних алгебраїчних рівнянь (СЛАР).

Квадратурні формули для 2π періодичних функцій. Для 2π -періодичних функцій інтеграція повторюється з періодом 2π , тому функції можуть бути апроксимовані на основі їхніх періодичних властивостей. Оскільки функція має період 2π , можна обчислювати інтеграл лише на відрізку $[0, 2\pi]$, що значно спрощує задачу. Нагадаємо, що квадратурна формула трапеції для періодичних функцій має вигляд:

$$\frac{1}{2\pi} \int_0^{2\pi} f(t) dt \approx \frac{1}{2N} \sum_{j=0}^{2N-1} f(t_j), \quad t_j = \frac{j\pi}{N}.$$

Для наближеного обчислення інтегралу з логарифмічною особливістю будемо квадратуру, у якій гладку частину підінтегральної функції

наближаємо тригонометричним інтерполяційним поліномом і далі інтегруємо точно [3]. У результаті отримуємо квадратурну формулу :

$$\frac{1}{2\pi} \int_0^{2\pi} f(\tau) \ln \left(\frac{4}{e} \sin^2 \frac{t - \tau}{2} \right) d\tau \approx \frac{1}{2N} \sum_{j=0}^{2N-1} f(t_j) R_j(t),$$

де

$$R_j(t) = -\frac{1}{2M} \left[1 + 2 \sum_{m=1}^{M-1} \frac{1}{m} \cos(m(t - t_j)) + \frac{1}{M} \cos(M(t - t_j)) \right]$$

— вагові функції для визначення впливу кожної точки у чисельному інтегруванні. Тоді ліва частина рівняння набуває вигляду:

$$\sum_{j=0}^{2N-1} \tilde{\mu}(t_j) \left\{ H_1(t_k, t_j) R_j(t_k) + \frac{1}{2N} H_2(t_k, t_j) \right\} = f^*(t_k),$$

де $\tilde{\mu}(t_j) \approx \mu(t_j)$, $i = 0, \dots, 2N - 1$.

Sinc-квадратура. Для інтегралів, що обчислюють за допомогою функції Гріна, застосовують методи, які можуть коректно обробляти сингулярність, наприклад, sinc-квадратура. Тому має місце наступна теорема.

Теорема 1.3.1. *Нехай $F(\tau)$ інтегровна на всій дійсній осі R , і нехай вона зменшується достатньо швидко при $|\tau| \rightarrow \infty$. Тоді інтеграл:*

$$I = \int_{-\infty}^{+\infty} F(\tau) d\tau$$

можна наближено обчислити за формулою:

$$I \approx h_\infty \sum_{j=-M}^M F(\tilde{t}_j),$$

де вузли $\tilde{t}_j$ і крок h_∞ визначаються як $\tilde{t}_j = jh_\infty$, $h_\infty = \frac{C}{\sqrt{M}}$, $C > 0$.

СЛАР. Використавши вищенаведені методи, запишемо таку систему рівнянь:

$$A\tilde{\mu} = \tilde{F},$$

причому

$$A_{ij} = R_j(t_i)H_1(t_i, t_j) + \frac{1}{2N}H_2(t_i, t_j).$$

Права частина матиме вигляд:

$$\tilde{F}_i = \tilde{f}_2(t_i) + h_\infty \sum_{j=-M}^M \tilde{f}_1(\tilde{t}_j)L(t_i, \tilde{t}_j).$$

Отже, наближений розв'язок буде мати наступний вигляд:

$$u_M(x) = \frac{\pi}{M} \sum_{j=0}^{2M-1} \mu_j G(x, x_2(t_j)) - h_\infty \sum_{j=-M}^M f_1(x_1(t_j)) \tilde{L}(x, x_1(t_j)), \quad x \in D,$$

де

$$\tilde{L}(x, y) = -\frac{1}{\pi} \frac{x_2 - y_2}{|x - y|^2} + \frac{1}{\pi} \frac{x_2 - y_2^*}{|x - y^*|^2}.$$

Розділ 2

Математична модель нейромережевої апроксимації та програмна реалізація

Сучасний розвиток методів обчислювальної математики та концепції наукового машинного навчання зумовив появу безсіткових методів моделювання фізичних полів. Замість традиційного дискретного представлення невідомих функцій у вигляді векторів фіксованої розмірності СЛАР, пропонується використання штучних нейронних мереж як універсальних аналітичних апроксиматорів. У цьому розділі детально формалізовано математичну модель нейромережевої апроксимації (підхід Physics-Informed Neural Networks, PINN [5]), описано пошарову структуру відображення сигналів, виведено аналітичну структуру цільової функції втрат та розглянуто процеси оптимізації параметрів. Також наведено детальний опис архітектури розробленого програмного комплексу, інструментарію розробки, функціональних можливостей користувацького інтерфейсу та засобів візуалізації результатів.

2.1. Архітектура багат шарового перцептрона як універсального апроксиматора

У основі нейромережевого моделювання крайових задач лежить фундаментальна теорема про універсальну апроксимацію (теорема Цибенка–Хорніка). Вона доводить, що повнозв’язна нейронна мережа здатна наблизити будь-яку неперервну функцію на компактній множині з довільною точністю за умови достатньої кількості нейронів та використання нелінійних гладких функцій активації.

Для розв’язання нашої задачі виконаємо заміну невідомої неперервної функції густини потенціалу $\mu(t)$ на її неперервний нейромережевий аналог $\mu_\theta(t)$:

$$\mu(t) \approx \mu_\theta(t), \quad (2.1)$$

де θ представляє сукупний вектор усіх внутрішніх параметрів штучної нейромережі, який підлягає оптимізації в процесі навчання.

Математична модель багат шарового перцептрона (MLP[7]) для нашої задачі здійснює відображення з одновимірному простору параметризації контуру в одновимірний простір шуканих значень густини ($R^1 \rightarrow R^1$). Пошаровий процес прямого поширення сигналу (forward pass) через мережу з L прихованими шарами описується системою матрично-векторних рівнянь нелінійного відображення:

$$z^{(1)} = W^{(1)}t + b^{(1)}, \quad a^{(1)} = \sigma(z^{(1)}), \quad (2.2)$$

$$z^{(l)} = W^{(l)}a^{(l-1)} + b^{(l)}, \quad a^{(l)} = \sigma(z^{(l)}), \quad l = 2, 3, \dots, L, \quad (2.3)$$

$$\mu_\theta(t) = W^{(L+1)}a^{(L)} + b^{(L+1)}, \quad (2.4)$$

де $t \in [0, 2\pi]$ — скалярний вхідний параметр моделі; $W^{(l)} \in R^{n_l \times n_{l-1}}$ — матриця вагових коефіцієнтів зв’язків l -го шару; $b^{(l)} \in R^{n_l}$ — вектор зміщень (biases) нейронів; $z^{(l)}$ — вектор лінійних комбінацій; $a^{(l)}$ — вектор вихідних активацій шару.

Схематичне зображення архітектури застосованого багат шарового перцептрона наведено на рис. 2.1.




Рис. 2.1: Архітектура фізично-інформованого багат шарового перцептрона

Для побудови гладкого аналітичного розв'язку критично важливою є диференційовність активаційної функції. У зв'язку з цим, на кожному прихованому шарі нашої моделі застосовано нелінійну функцію гіперболічного тангенсу ($\tanh$):

$$\sigma(z) = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}. \quad (2.5)$$

Вихідний шар нейронної мережі містить один нейрон з лінійною функцією активації, що дозволяє мережі генерувати довільні дійсні значення густини потенціалу.

2.2. Фізично-інформована функція втрат та оптимізація параметрів

У класичних задачах машинного навчання цільова функція втрат мінімізує відхилення від еталонного датасету. Оскільки в нашій задачі точний розв'язок інтегрального рівняння $\mu(t)$ є апіорі невідомим, мережа інформується про закони математичної фізики шляхом інтеграції самого дискретизованого інтегрального оператора безпосередньо в структуру цільового функціоналу.

Для формування функції втрат розіб'ємо відрізок параметризації межі $[0, 2\pi]$ на дискретну сітку з $2N$ рівновіддалених вузлів колокації $t_i = \frac{i\pi}{N}$ ($i = 0, \dots, 2N-1$). Підставляючи вихід нейромережі $\mu_\theta(t_j)$ у дискретну суму квадратурного представлення Кресса, ми формулюємо функцію втрат як

середньоквадратичну нев'язку (MSE) інтегрального рівняння в усіх вузлах колокації:

$$L(\theta) = \frac{1}{2N} \sum_{i=0}^{2N-1} \left(\sum_{j=0}^{2N-1} A_{ij} \mu_{\theta}(t_j) - f^*(t_i) \right)^2 \rightarrow \min_{\theta}. \quad (2.6)$$

Тут матриця квадратурних коефіцієнтів A_{ij} виступає в ролі фіксованого лінійного оператора (математичного “якоря”), який обчислюється один раз на початку програми на основі формули Кресса і не змінюється протягом усього процесу навчання. Таким чином, нейромережа штрафується щоразу, коли згенерована нею функція густини не задовольняє інтегральний оператор Лапласа.

Мінімізація сформованого функціоналу втрат (2.6) здійснюється за допомогою алгоритму зворотного поширення помилки (Backpropagation), який базується на диференціюванні складеної функції за ланцюговим правилом. У нашому випадку градієнт функціоналу $L(\theta)$ за довільним ваговим коефіцієнтом мережі w обчислюється за наступною схемою:

$$\frac{\partial L}{\partial w} = \frac{1}{N} \sum_{i=0}^{2N-1} \left(\sum_{m=0}^{2N-1} A_{im} \mu_{\theta}(t_m) - f^*(t_i) \right) \cdot \left(\sum_{j=0}^{2N-1} A_{ij} \frac{\partial \mu_{\theta}(t_j)}{\partial w} \right). \quad (2.7)$$

Компоненти частинних похідних виходу нейронної мережі за її внутрішніми параметрами $\frac{\partial \mu_{\theta}(t_j)}{\partial w}$ обчислюються автоматично фреймворком PyTorch [6] шляхом побудови динамічного обчислювального графа прямого ходу.

Наявність кастомного інтегрального оператора A_{ij} всередині цільової функції вимагає від обчислювального ядра точного збереження градієнтних потоків для всіх $2N$ точок сітки одночасно, що успішно забезпечується модулем автоматичного диференціювання `torch.autograd`.

Для ітераційного оновлення вектора параметрів θ використовується сучасний оптимізатор Adam. Математичний крок оновлення ваг на ітерації k описується рівняннями:

$$m_k = \beta_1 m_{k-1} + (1 - \beta_1) g_k, \quad v_k = \beta_2 v_{k-1} + (1 - \beta_2) g_k^2, \quad (2.8)$$

$$\hat{m}_k = \frac{m_k}{1 - \beta_1^k}, \quad \hat{v}_k = \frac{v_k}{1 - \beta_2^k}, \quad \theta_k = \theta_{k-1} - \frac{\eta}{\sqrt{\hat{v}_k} + \epsilon} \hat{m}_k, \quad (2.9)$$

де $\eta = 0.005$ — швидкість навчання; $\beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}$ — стандартні гіперпараметри. Процес оптимізації триває рівно 3000 епох.

Протягом цього циклу параметри мережі налаштовуються таким чином, щоб випадковий початковий шум на виході перцептрона трансформувався в абсолютно гладку аналітичну криву, яка мінімізує глобальну середньоквадратичну нев'язку інтегрального рівняння Лапласа до рівня машинної точності.

2.3. Програмний комплекс та математичний зв'язок з інтерфейсом

Інтерфейс користувача, побудований на базі Streamlit, не є просто "обгорточкою". Це повноцінний контролер, який керує станом (state) обчислювальної моделі. Розглянемо детальніше логіку функціонування кожного елемента.

Математичний зв'язок між UI та Backend. Кожен віджет у боковій панелі (Sidebar) напряму мапується на гіперпараметри моделі.

- **Селектор геометрії:** при зміні значення (наприклад, зі "Зміщене коло" на "Область 'Гантеля'"), функція обробки викликає регенерацію контурів Γ_2 , перераховує матрицю A_{ij} та скидає ваги нейромережі до початкового стану.




Рис. 2.2: Селектор вибору геометрії області в інтерфейсі програми

- **Слайдери дискретизації (N, M):** ці параметри визначають розмірність простору колокації. Зміна N ініціює повну перебудову тензорів

у пам'яті PyTorch [6], що є критичним для забезпечення коректності градієнтного кроку Adam.




Рис. 2.3: Панель налаштування параметрів дискретизації простору

- **Гіперпараметри нейромережі:** цей блок дозволяє гнучко налаштовувати архітектуру багатошарового перцептрона (кількість прихованих шарів та нейронів у кожному з них), а також керувати процесом оптимізації, задаючи загальну кількість епох навчання та крок градієнтного спуску (Learning Rate) для алгоритму Adam. Кнопка ініціалізації запускає процес перерахунку.




Рис. 2.4: Панель налаштування гіперпараметрів нейромережі

2.4. Моніторинг навчального процесу та інтерпретація результатів


Моніторинг навчального процесу (Live Training Loop). Однією з ключових особливостей нашого комплексу є динамічна візуалізація навчання в реальному часі. Використання механізму `st.empty()` дозволяє оновлювати графіки без перезавантаження сторінки, що створює ефект "живої" оптимізації.

Процес навчання розбито на батчі (batches) по 100 епох. Після кожного батчу інтерфейс отримує поточний вектор параметрів θ , виконує forward pass для набору тестових точок і оновлює:

1. **Графік Loss:** відображається поточне значення $L(\theta)$. Важливо, що ми використовуємо логарифмічну шкалу (натисканням кнопки "Log Scale" в налаштуваннях), оскільки значення Loss падають на кілька порядків (від 10^0 до 10^{-6}), що робить звичайну лінійну шкалу неінформативною.

Процес оптимізації для конфігурації: Зміщене коло...

Епоха: 3000/3000 | MSE Loss: 2.381260e-04



✓ Процес навчання успішно завершено.

Рис. 2.5: Динаміка мінімізації функції втрат $L(\theta)$ у логарифмічному масштабі під час навчання

2. **Обчислення абсолютної похибки:** $|u_{exact} - u_{NN}|$. Ми додали опцію інтерактивної верифікації, що дозволяє порівнювати нейромережевий

розв'язок з аналітичним еталоном та класичним методом Нистрьома. Як видно на рис. 2.6, запропонована нейромережева модель демонструє високу точність наближення, де відхилення є у більшості точок не перевищує 10^{-4} , що підтверджує ефективність обраної архітектури для розв'язання крайових задач.

Верифікація наближеного розв'язку в заданій точці області

Введіть координату x_1 : - + Введіть координату x_2 : - +

Результати обчислень:

- ◆ Класичний метод (Nyström/СЛАР): 0.2510773774
- ◆ Запропонований метод (Нейромережа): 0.2507311585

Абсолютна розбіжність між методами: 3.46218871e-04

📖 Аналітичний еталон: 0.2450365158

Похибка класичного методу відносно еталона: 6.04086162e-03

Похибка нейромережевого алгоритму відносно еталона: 5.69464275e-03

Рис. 2.6: Порівняльна характеристика похибки розв'язку: нейромережа проти класичного методу

- Візуалізація густини потенціалу:** інтерфейс автоматично будує графік апроксимованої густини $\mu(t)$ після завершення навчання. Це дозволяє візуально контролювати гладкість функції, що є критично важливим для інтегральних рівнянь, оскільки нефізичні осциляції на графіку $\mu(t)$ часто свідчать про неправильний вибір гіперпараметрів.




Рис. 2.7: Графік апроксимованої густини потенціалу $\mu(t)$, отриманий неймережею

Аналіз візуалізації. Графіки будуються на основі трьох джерел даних:

- **Static Reference:** статичні дані для "гантелі" або "кола згенеровані класичним методом Нистрьома при $M = 1000$ і збережені у форматі '.пру' для миттєвого завантаження.
- **Dynamic Solution (СЛАР):** обчислюється для заданого N на кожній ітерації користувача. Це дозволяє порівняти класичну дискретизацію з неймережевою апроксимацією "на льоту".
- **NN Inference:** результат роботи методу 'forward()' неймережі, отриманий на поточній епосі.

Така архітектура дозволяє користувачеві не просто споглядати фінальний результат, а бачити, як саме неймережа "вчиться" задовольняти рівняння Лапласа, поступово зменшуючи відхилення від еталонного методу. Детальний опис кожного графіку, наведений у таблиці 2.1, допомагає користувачеві інтерпретувати результати навчання.

Елемент	Призначення та джерело даних
Loss Chart	Динаміка $L(\theta)$. Дані: 'history' (масив помилок по епохах).
Error Heatmap	Локалізація похибки. Дані: $ u_{exact}(t_i) - \mu_\theta(t_i) $.
Density Plot	Візуалізація густини μ_θ . Дані: тензор виходу 'model(t)'.

Табл. 2.1: Опис функціональних елементів інтерфейсу

Інтерпретація отриманих результатів. Користувач отримує можливість бачити, як зміна гіперпараметрів (наприклад, кількості шарів) змінює кривизну апроксимованої густини потенціалу. Якщо графік похибки має виражені піки в місцях "впадин" контуру гантелі це чіткий індикатор того, що поточна архітектура потребує глибшої мережі (більшої кількості прихованих шарів).

Розділ 3

Результати чисельних експериментів

Практична верифікація розробленої математичної моделі та оцінка її узагальнюючої здатності вимагає проведення серії комплексних чисельних експериментів. Головною метою цього розділу є емпіричне дослідження точності, збіжності та стабільності фізично-інформованого нейромережевого підходу (PINN) у зіставленні з класичним методом квадратур Нистрьома (СЛАР). Моделювання проводилося для трьох типів граничних контурів: аналітично простого «Зміщеного кола», геометрично ускладненого неперепуклого контуру «Гантелі» та «Еліпса».

3.1. Конфігурація обчислювального середовища

Усі чисельні розрахунки проводилися на базі розробленого програмного комплексу в уніфікованому середовищі. Обчислювальне ядро використовувало апаратні можливості центрального процесора, система оперувала типом даних `torch.float64` для мінімізації похибок округлення.

Для кожної геометричної області було зафіксовано наступні параметри:

- кількість вузлів для Sinc-квадратурної схеми на нескінченній межі Γ_1 встановлено на рівні $M = 1000$ при кроці $h_\infty = 1/\sqrt{M} \approx 0.0316$.

- еталонний розв'язок $u_{exact}(x)$ у тестових точках обчислювався за допомогою матричного методу на надгустій сітці з $2N = 2000$ вузлів.
- навчання нейромережевої моделі: 3 приховані шари по 50 нейронів, $\eta = 0.005$, 3000 епох оптимізації.

3.2. Приклад 1. Зміщене коло

$$\Gamma_1 = \{(t, 0)\}, \quad (3.1)$$

$$\Gamma_2 = \{x(t) = (\cos(t), \sin(t) + 2)\}, \quad t \in [0, 2\pi], \quad (3.2)$$

$$f_1(x) = \exp(-x_1^2), \quad x \in \Gamma_1, \quad (3.3)$$

$$f_2(x) = 1, \quad x \in \Gamma_2. \quad (3.4)$$




Рис. 3.1: Область D

N	Тестова точка x	Класичний метод (СЛАР)	НМ (PINN)	Абсолютна розбіжність
8	(0, 4)	0.7804501219	0.7921820745	$1.17 \cdot 10^{-2}$
8	(4, 2)	0.2726550388	0.2745924381	$1.93 \cdot 10^{-3}$
16	(0, 4)	0.7443923340	0.7429414796	$1.45 \cdot 10^{-3}$
16	(4, 2)	0.2576049666	0.2576962542	$9.12 \cdot 10^{-5}$
32	(0, 4)	0.7256279582	0.7261261038	$4.98 \cdot 10^{-4}$
32	(4, 2)	0.2510773774	0.2388727697	$1.22 \cdot 10^{-2}$

Табл. 3.1: Результати прикладу 1

Аналізуючи отримані результати для тестового прикладу зі зміщеним колом, можна відмітити нелінійну залежність точності нейромережевої апроксимації від розмірності простору дискретизації N . Найвища точність та найкраще узгодження між класичним методом і розробленою нейромережевою моделлю спостерігається при $N = 16$, де абсолютна розбіжність в окремих точках досягає порядку 10^{-5} .

Проте при подальшому збільшенні кількості вузлів колокації до $N = 32$ фіксується локальне зростання похибки (до 10^{-2} для точки $x = (4, 2)$). Така поведінка є характерною особливістю методів машинного навчання, зокрема фізично-інформованих нейромереж (PINN). Надмірне збільшення кількості точок, у яких обчислюється нев'язка інтегрального рівняння, без відповідного пропорційного збільшення ємності моделі (кількості прихованих шарів та нейронів) суттєво ускладнює ландшафт цільової функції втрат. Оптимізатору стає складніше знайти глобальний мінімум, що призводить до ефекту "недонавчання" (underfitting) через надмірну кількість обмежень.

Отже, для областей з гладкою межею без суттєвих геометричних особливостей використання помірної кількості вузлів ($N = 16$) є оптимальним, оскільки забезпечує ідеальний баланс між інформативністю фізичної складової функції втрат та здатністю перцептрона до її мінімізації.

3.3. Приклад 2. Гантелеподібна область

$$\Gamma_2 = \{(r(t) \cos(t), r(t) \sin(t) + 1.5), \quad t \in [0, 2\pi]\}, \quad (3.5)$$

$$\text{де } r(t) = \sqrt{\cos^2(t) + 0.25 \sin^2(t)}, \quad (3.6)$$

$$f_1(x) = \exp(-x_1^2), \quad x \in \Gamma_1, \quad (3.7)$$

$$f_2(x) = 1, \quad x \in \Gamma_2. \quad (3.8)$$




Рис. 3.2: Область D

N	Тестова точка x	Класичний метод (СЛАР)	НМ (PINN)	Абсолютна розбіжність
8	(4, 2)	0.2453506308	0.2469590020	$1.60 \cdot 10^{-3}$
8	(2, 2)	0.6230691924	0.6241405147	$1.07 \cdot 10^{-3}$
16	(4, 2)	0.2222362914	0.2173284122	$4.90 \cdot 10^{-3}$
16	(2, 2)	0.5563209138	0.5589431846	$2.62 \cdot 10^{-3}$
32	(4, 2)	0.2160808124	0.2161232038	$4.23 \cdot 10^{-5}$
32	(2, 2)	0.5402338213	0.5424689840	$2.23 \cdot 10^{-3}$

Табл. 3.2: Результати прикладу 2

Експерименти для гантелеподібної області підтверджують стабільність нейромережевого алгоритму навіть при складній геометрії. Зі збільшенням N до 32 точність суттєво зростає: для точки $(4, 2)$ розбіжність зменшується до $4.23 \cdot 10^{-5}$. Попри складність контуру, модель коректно обробляє сингулярності та забезпечує точність, співставну з класичними методами.

3.4. Приклад 3. Еліптична область

$$\Gamma_1 = \{(t, 0)\}, \quad (3.9)$$

$$\Gamma_2 = \{x(t) = (2 \cos(t), \sin(t) + 2), \quad t \in [0, 2\pi]\}, \quad (3.10)$$

$$f_1(x) = \exp(-x_1^2), \quad x \in \Gamma_1, \quad (3.11)$$

$$f_2(x) = 1, \quad x \in \Gamma_2. \quad (3.12)$$




Рис. 3.3: Область D

N	Тестова точка x	Класичний метод (СЛАР)	НМ (PINN)	Абсолютна розбіжність
8	(0, 4)	0.6389893135	0.6215065590	$1.75 \cdot 10^{-2}$
8	(4, 2)	0.3176481643	0.3259330236	$8.28 \cdot 10^{-3}$
16	(0, 4)	0.6037516418	0.5990653856	$4.69 \cdot 10^{-3}$
16	(4, 2)	0.3075911252	0.3084887470	$8.98 \cdot 10^{-4}$
32	(0, 4)	0.5910801734	0.5885199009	$2.56 \cdot 10^{-3}$
32	(4, 2)	0.3008479211	0.3012637585	$4.16 \cdot 10^{-4}$

Табл. 3.3: Результати прикладу 3

Експерименти для еліптичної області підтверджують збіжність розробленого методу для контурів з різним рівнем кривизної деформації вздовж осей. Як видно з таблиці 3, зі збільшенням сітки до $N = 32$ алгоритм стабільно мінімізує похибку, досягаючи рівня $4.16 \cdot 10^{-4}$ для точки (4, 2).

Висновки

У даній роботі проведено комплексне дослідження методів наближеного розв'язування крайової задачі Діріхле для рівняння Лапласа в частково необмежених областях. Основна увага приділялася поєднанню класичної теорії потенціалу з підходами машинного навчання, зокрема застосуванню архітектур, споріднених з фізично-інформованими нейронними мережами (PINN). За результатами виконання роботи можна зробити наступні висновки:

1. Математичну постановку задачі успішно зведено до граничного інтегрального рівняння першого роду. Для коректної обробки логарифмічної особливості в ядрі (функції Гріна) застосовано спеціальні вагові тригонометричні квадратурні формули. Це дозволило побудувати надійний дискретний аналог класичним методом Нистрьома для подальшої верифікації результатів.
2. Запропоновано та програмно реалізовано альтернативний метод розв'язування, у якому невідома густина потенціалу $\mu(t)$ апроксимується за допомогою багатошарового перцептрона (MLP). Відмова від формування та розв'язування щільних систем лінійних алгебраїчних рівнянь (СЛАР) дозволила уникнути проблеми накопичення обчислювальної похибки. Навчання мережі відбувається "на льоту" шляхом мінімізації нев'язки інтегрального рівняння у вузлах колокації (MSE Loss), що повністю виключає необхідність попередньої підготовки зовнішніх навчальних датасетів.
3. Програмну реалізацію обчислювального алгоритму виконано мовою Python з використанням фреймворку PyTorch. Для зручності проведення чисельних експериментів розроблено інтерактивний веб-застосунок на базі бібліотеки Streamlit, який дозволяє керувати гіперпараметра-

ми мережі, параметрами області та візуалізувати динаміку мінімізації функції втрат у реальному часі.

4. Проведено серію обчислювальних експериментів на областях з різною геометрією (зміщене коло, еліпс, область із звуженням типу "гантеля"). Результати порівняльного аналізу показали, що запропонований нейромережевий підхід досягає високої точності — абсолютна розбіжність із класичним методом в окремих тестових точках становить $10^{-4} \dots 10^{-5}$.
5. Досліджено вплив параметрів дискретизації на якість апроксимації. Встановлено нелінійну залежність точності від кількості вузлів колокації N . Зокрема, оптимальна точність для більшості експериментів досягалася при помірній дискретизації ($N = 16$). При надмірному збільшенні кількості точок (наприклад, $N = 32$) без відповідного збільшення ємності мережі фіксувалося локальне зростання похибки. Це пояснюється переускладненням ландшафту цільової функції та труднощами оптимізатора при пошуку глобального мінімуму, що призводить до ефекту недонавчання.

Отримані результати підтверджують практичну доцільність та ефективність використання архітектур глибокого навчання для розв'язування інтегральних рівнянь. Подальші дослідження у цьому напрямку можуть бути зосереджені на застосуванні складніших оптимізаторів, дослідженні тривимірних постановок задач, а також оптимізації обчислювального процесу для роботи зі складною геометрією меж.

Прикінцеві положення

Декларація про використання генеративного штучного інтелекту

Під час підготовки цієї курсової роботи було використано системи генеративного штучного інтелекту (зокрема, великі мовні моделі) виключно як допоміжний інструмент для:

- стилістичного та граматичного редагування тексту;
- форматування математичних формул і побудови таблиць у середовищі LaTeX.


Підтверджено, що вся математична постановка задачі, розробка архітектури штучної нейронної мережі, написання програмного коду, проведення чисельних експериментів та аналіз отриманих результатів є результатом виключно власної самостійної наукової роботи і не були згенеровані штучним інтелектом.

Апробація результату

Основні наукові та практичні результати, отримані в ході виконання даної роботи, були апробовані та представлені у вигляді доповіді на міжнародній студентській науковій конференції з прикладної математики з прикладної математики та комп'ютерних наук - АМІСоп 2026 у Львівському національному університеті імені Івана Франка на факультеті прикладної математики та інформатики. Окрім того, результати інтегровані в розробку програмного комплексу для дослідження граничних інтегральних рівнянь методами машинного навчання.

Посилання на репозиторій з вихідним кодом та інструкції

Репозиторій **GitHub**: github.com/bohdanahorbachuk/Neural-Network-Solver...



QR-код для швидкого доступу до вихідного коду

Опис проєкту та математичної моделі:

Репозиторій містить програмну реалізацію до курсової роботи, присвяченої наближеному розв'язуванню інтегральних рівнянь за допомогою штучних нейронних мереж на прикладі крайової задачі Діріхле для рівняння Лапласа в частково необмеженій області.

Обчислювальне ядро використовує підхід, споріднений з Physics-Informed Neural Networks (PINN). Задача зводиться до інтегрального рівняння першого роду з логарифмічною особливістю за допомогою функції Гріна. Замість дискретизації рівняння та розв'язання щільної СЛАР (як у класичному методі Нистрьома), невідома густина потенціалу $\mu(t)$ апроксимується багатопарним перцептроном. Мережа навчається "на льоту" (без використання зовнішніх датасетів), мінімізуючи нев'язку інтегрального рівняння (MSE Loss) у заданих точках колокації.

Технологічний стек та залежності:

Для коректної роботи застосунку потрібен інтерпретатор Python версії 3.9 або вище. Основні залежності проєкту (описані у файлі `requirements.txt`):

- **torch** (PyTorch) — для побудови, оптимізації нейромережі та автоматичного диференціювання;
- **streamlit** — для візуалізації процесу навчання та створення графічного інтерфейсу;

- `numpy`, `matplotlib` — для обчислення тригонометричних квадратур та візуалізації результатів.

Інструкція з локального запуску:

1. Клонувати репозиторій на локальну машину:
`git clone https://github.com/bohdanahorbachuk/Neural-Network-Solver-for-Integral-Equations.git`
2. Перейти в директорію проєкту:
`cd Neural-Network-Solver-for-Integral-Equations`
3. Створити та активувати віртуальне середовище:
`python -m venv .venv`
 Для macOS / Linux: `source .venv/bin/activate`
 Для Windows: `.venv\Scripts\activate`
4. Встановити необхідні залежності:
`pip install -r requirements.txt`
5. Запустити локальний сервер Streamlit:
`streamlit run app.py`
6. Застосунок буде доступний у браузері за адресою: `http://localhost:8501`.

Структура інтерфейсу (Usage):

У бічній панелі веб-застосунку користувачеві доступні такі налаштування:

- *Вибір межі області (Γ_2):* тестування на різних геометріях (зміщене коло, гантеля, еліпс) для перевірки узагальнювальної здатності алгоритму.
- *Параметри дискретизації:* вибір кількості вузлів інтегрування N для побудови матриці квадратур.
- *Гіперпараметри НМ:* гнучке налаштування кількості прихованих шарів, нейронів, швидкості навчання (learning rate) та кількості епох.

Після завершення процесу оптимізації відкривається блок верифікації (Inference). Користувач може ввести координати довільної тестової точки всередині області для прямого порівняння абсолютної похибки між класичним методом та натренованою нейромережею.

Хмарне розгортання (деплоймент):

Розроблений програмний комплекс успішно розгорнуто на спеціалізованій платформі *Streamlit Community Cloud*, що забезпечує кросплатформний доступ до веб-інтерфейсу без необхідності локального налаштування середовища та встановлення інтерпретатора Python користувачем.

Публічне посилання на робочий застосунок: <https://neural-network-solver-for-integral-equations-x2nkyx2yy6yynx652.streamlit.app/>

Процес розгортання реалізовано шляхом прямої синхронізації хмарної платформи з основним репозиторієм GitHub. Платформа автоматично ізолює середовище, завантажує всі необхідні обчислювальні залежності з файлу `requirements.txt` і забезпечує безперервну інтеграцію (Continuous Integration): будь-які оновлення вихідного коду в гілці `main` автоматично компілюються та відображаються у публічному веб-застосунку.

Особливості хмарних обчислень та продуктивність.

Варто зазначити, що безкоштовний тариф платформи Streamlit Community Cloud має жорсткі апаратні обмеження (відсутність GPU та лімітований об'єм оперативної пам'яті). Оскільки процес навчання фізично-інформованої нейромережі (PINN) "на льоту" вимагає інтенсивних тензорних обчислень та багаторазового перерахунку градієнтів (алгоритм Backpropagation), виконання повноцінного циклу оптимізації на 3000 епох у хмарному середовищі може потребувати значного часу. Для швидкої демонстрації роботи алгоритму в браузері рекомендується зменшити кількість епох до 300-500. Для отримання розв'язку з максимальною точністю (порядку 10^{-5}) доцільно використовувати локальний запуск комплексу на апаратному забезпеченні користувача.

Список використаних джерел

- [1] Chapko, R. On the numerical solution of the boundary value problem in the theory of elasticity for a doubly connected domain. *Mathematics and Computers in Simulation*, 66(4-5), 425–438 (2004).
- [2] Chapko, R., Kress, R. A hybrid method for inverse boundary value problems in potential theory. *Journal of Inverse and Ill-Posed Problems*, 13(1), 27–40 (2005).
- [3] Kress, R. *Linear Integral Equations*. 3rd edn. Springer, Berlin (2014).
- [4] Chapko, R., Johansson, B.T. An alternating boundary integral-based method for a Cauchy problem for the Laplace equation in semi-infinite regions. *Journal of Inverse and Ill-Posed Problems*, 16(4), 317–333 (2008).
- [5] Raissi, M., Perdikaris, P., Karniadakis, G. E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, 378, 686–707 (2019).
- [6] Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... & Chintala, S. PyTorch: An Imperative Style, High-Performance Deep Learning Library. In *Advances in Neural Information Processing Systems 32*, 8024–8035 (2019).
- [7] Goodfellow, I., Bengio, Y., Courville, A. *Deep Learning*. MIT Press (2016).